

Zilla KB – Answer Quality Evaluation Report

LLM-as-a-Judge bake-off • 2026-08-22 • threshold 0.5 • sample: 5 Arabic Q&A pairs

Goal. Pick a judge model that automatically grades Zilla's voice-assistant answers on two dimensions:

Relevancy – does the answer address the question?

Faithfulness – is every claim backed by the retrieved knowledge-base context?

1. Judge bake-off (same 5 questions)

Judge model	Avg Relevancy	Avg Faithfulness	Wall time / 5 q	Cost	Poison test
gpt-oss-120b (Groq API)	1.00 🏆	1.00 🏆	2.7 min	\$0	caught all faults
nemotron-3-ultra-550b (OpenRouter free)	0.72	0.90	10.1 min	\$0	–
qwen2.5:7b (local GPU)	0.62	0.57	~3 min	\$0	unstable

Decision: adopt **gpt-oss-120b via Groq** as the official judge — best accuracy, 4× faster than the runner-up, zero cost. The local model stays as an offline fallback only.

2. Official run – questions, Zilla's answers, scores

Q: ما الشرط الأساسي لإنشاء طلب تركيب لوحة؟

Q049 • AR

Zilla's answer: الشرط الأساسي لإنشاء طلب تركيب لوحة بريدية هو أن يكون العميل مسجلاً في العنوان الوطني، ويكون نوع الوحدة السكنية قتيلاً أو دويلكس. الخدمة غير متاحة لأصحاب الشقق أو الحسابات التجارية والحكومية. أيضاً يجب أن يكون العنوان مسجلاً في إحدى المدن التي تشملها ... الخدمة. تحتاج أي مساعدة إضافية بخصوص اللوحات البري

Relevancy

1.00 ✓

Faithfulness

1.00 ✓

Q: هل يمكن للعميل تصميم لوحة والتعامل مع مصنع آخر مباشرة؟

Q079 • AR

Zilla's answer: نعم، بإمكان العميل تصميم وتصنيع اللوحة البريدية بنفسه أو عن طريق مصنع آخر غير المعتمد من سُبُل، بشرط الالتزام بالمواصفات والمقاسات المعتمدة. يستطيع العميل تحميل ملف المواصفات من منصة سُبُل باختيار خيار أرغب في تصنيع اللوحة من مزود آخر. إذا تحتاج تفاصيل أكثر ... عن المواصفات أو خطوات التحميل بلغيني. أي خدمة

Relevancy

1.00 ✓

Faithfulness

1.00 ✓

Q: في أي مدن تكون خدمة تركيب اللوحات متاحة حالياً؟

Q013 • AR

Zilla's answer: خدمة تركيب اللوحات البريدية متاحة حالياً في المدن التالية الرياض، جدة، الدمام، الخبر، الظهران، مكة المكرمة، المدينة المنورة، حائل، جازان، حفر الباطن، نجران، عنيزة، بريدة، أبها، خميس مشيط، سيهات، تاروت، عنك، والقطيف. إذا تحتاجي تفاصيل أكثر عن الخدمة أو طريقة الطلب أفيدك. أي خدمة أخرى؟

Relevancy

1.00 ✓

Faithfulness

1.00 ✓

Q: من هم المستخدمون المؤهلون لخدمة تركيب اللوحات؟

Q009 • AR

Zilla's answer: المستخدمون المؤهلون لخدمة تركيب اللوحات البريدية هم الأفراد، سواء مواطنين أو مقيمين، المسجلين في العنوان الوطني ويقيمون في وحدات سكنية من نوع فيلا أو دوبلكس فقط. الخدمة غير متاحة لأصحاب الشقق أو حسابات الأعمال أو الحسابات الحكومية. إذا عندك استفسار ... عن أهلية معينة أو تفاصيل إضافية بلغيني. أي خدمة أ

Relevancy	Faithfulness
1.00 ✓	1.00 ✓

Q: كم مدة حل البلاغات لخدمة تركيب اللوحات؟

Q005 • AR

Zilla's answer: مدة حل البلاغات والشكاوى الخاصة بخدمة تركيب اللوحات البريدية هي 72 ساعة عمل كحد أقصى. إذا فيه أي تفاصيل أخرى تحبي تعرفينها عن الخدمة أبلغيني. أي خدمة أخرى؟

Relevancy	Faithfulness
1.00 ✓	1.00 ✓

Run usage: 35 LLM calls • 19,044 input tokens • 12,098 output tokens • 2.7 min wall time

3. Poison test – can the judge actually catch errors?

We deliberately corrupted real answers and checked that each metric fails exactly the answer type it guards against (“a judge that gives straight 100% proves nothing”).

Test case	Expected behaviour	Relevancy	Faithfulness	Result
Wrong cities Replaced the Saudi city list with Jordanian cities	Faithfulness must fail	1.00 ✓	0.00 ✗	Caught correctly
Off-topic reply Answer about weather and football instead of the question	Relevancy must fail	0.00 ✗	1.00 ✓	Caught correctly
Fabricated numbers Changed every number in the answer to 999	Faithfulness must fail	1.00 ✓	0.00 ✗	Caught correctly

Positive control

Untouched correct answer

Scores stay high

1.00 ✓

1.00 ✓

**Caught
correctly**

Result: 4/4 correct. Each metric caught its own fault type and never mis-fired – e.g. the off-topic reply correctly keeps Faithfulness high because it makes no false factual claims.

4. Method notes

- **Arabic-native judging:** Arabic answers are compared directly with their Arabic retrieval context – no translation step, eliminating translation-hallucination failures.
- **No claim truncation:** explicit instruction to copy sentences verbatim fixed the long-list case (19 cities) for every judge.
- **Natural closings:** phrases like “Any other service?” are treated as normal assistant behaviour, not penalized.
- **Auto-retry:** transient failures (malformed JSON, empty completions, HTTP 429) are retried up to 3 times automatically.
- **Per-judge result files:** switching judges can never overwrite another judge's scores.

5. Next step

Full official run over all **200 questions** (~25 minutes on Groq, well inside the free daily quota).

Generated automatically by the zilla-kb evaluation pipeline • sources: data/eval-results-*.json • comparison appendix: data/judge-comparison.md